

1. SUPPLEMENTARY MATERIAL

1.1. Group Sparsemax

原始优化问题为:

$$\max_{p \in \Delta^d} \frac{1}{2} (y - \sum_{i=1}^n p_i)^2 + \lambda \sum_{i=1}^n \|p_i\|_2, \quad (1)$$

其中 $p = \{p_1, p_2, p_3, \dots, p_n\}$ 是生成的概率分布, $p_i = \{\theta_i^1, \theta_i^2, \theta_i^3, \dots, \theta_i^m\}$ 是第 i 个组, θ_i^j 是第 i 个概率分组中的第 j 个概率元素, $\Delta^d = \{P \in R^d | 1^T P \leq 1, P \geq 0\}$ 是 d 维的概率单纯形。

将其转换为Group Lasso形式:

$$\begin{aligned} \max \quad & \frac{1}{2} (y - \sum_{i=1}^n H_i p_i)^2 + \lambda \sum_{i=1}^n \|p_i\|_2 \\ = & \frac{1}{2} (y - \sum_{i=1}^n H_i p_i)^T (y - \sum_{i=1}^n H_i p_i) + \lambda \sum_{i=1}^n \|p_i\|_2 \\ = & \frac{1}{2} (y^T - \sum_{i=1}^n p_i^T H_i^T) (y - \sum_{i=1}^n H_i p_i) + \lambda \sum_{i=1}^n \|p_i\|_2 \\ = & \frac{1}{2} (y^T y - y^T \sum_{i=1}^n H_i p_i - \sum_{i=1}^n p_i^T H_i^T y + \\ & \sum_{i=1}^n \sum_{j=1}^n p_i^T H_i^T H_j p_j) + \lambda \sum_{i=1}^n \|p_i\|_2 \\ = & \frac{1}{2} (y^T y - 2y^T \sum_{i=1}^n p_i + \sum_{i=1}^n p_i^T p_i) + \lambda \sum_{i=1}^n \|p_i\|_2 \\ \text{s.t.} \quad & 1^T p = 1, \\ & p \geq 0, \end{aligned} \quad (2)$$

其中 $H_i = \begin{bmatrix} 0 & 0 & \dots & 0 \\ \vdots & \vdots & \dots & \vdots \\ 0 & 0 & \dots & 0 \\ 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & \dots & \vdots \\ 0 & 0 & \dots & 0 \end{bmatrix}$.

Eq. 2的Larangian形式如下:

$$\begin{aligned} \mathcal{L}(y, \mu, \tau) = & \frac{1}{2} (y^T y - 2y^T \sum_{i=1}^n p_i + \sum_{i=1}^n p_i^T p_i) + \\ & \lambda \sum_{i=1}^n \|p_i\|_2 - \mu p + \tau (1^T p - 1). \end{aligned} \quad (3)$$

同时最优解 $\{p^*, \mu^*, \tau^*\}$ 需要满足下列的KKT条件:

1) 当 $p_i > 0$ 时,

$$p^* \geq 0, \mu^* \geq 0, \mu^* p = 0, 1^T p^* = 1 \quad (4)$$

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial p_i^*} = & -y_i^T + p_i^* + \lambda \frac{p_i^*}{\|p_i^*\|_2} + \tau^* 1^T - \mu_i^* = 0 \\ \Rightarrow & (1 + \frac{\lambda}{\|p_i^*\|_2}) p_i^* = y_i - \tau^* + \mu_i^* \\ \Rightarrow & p_i^* = (1 + \frac{\lambda}{\|p_i^*\|_2})^{-1} (y_i - \tau^* + \mu_i^*)_+ \end{aligned} \quad (5)$$

由于上式中存在 $\|p_i^*\|_2$, 因此将两面同时求 l_2 范数, 解出 $\|p_i^*\|_2$, 令 $s_i = (y_i - \tau^* + \mu_i^*)_+$, 其中 $s_{ij} = (\theta_i^j - \tau^* + \mu_{ij}^*)_+$.

$$\begin{aligned} \|p_i^*\|_2 = & \|(1 + \frac{\lambda}{\|p_i^*\|_2})^{-1} s_i\|_2 \\ \|p_i^*\|_2 = & \sqrt{(1 + \frac{\lambda}{\|p_i^*\|_2})^{-2} \sum_{j=1}^m s_{ij}^2} \\ \|p_i^*\|_2 = & (1 + \frac{\lambda}{\|p_i^*\|_2})^{-1} \|s_i\|_2 \\ \|p_i^*\|_2 (1 + \frac{\lambda}{\|p_i^*\|_2}) = & \|s_i\|_2 \\ \|p_i^*\|_2 + \lambda = & \|s_i\|_2 \\ \|p_i^*\|_2 = & \|s_i\|_2 - \lambda \end{aligned} \quad (6)$$

将求得的 $\|p_i^*\|_2$ 带入Eq. 5:

$$\begin{aligned} p_i^* = & (1 + \frac{\lambda}{\|s_i\|_2})^{-1} s_i \\ p_i^* = & (1 - \frac{\lambda}{\|s_i\|_2}) s_i \end{aligned} \quad (7)$$

2) 当 $p_i = 0$ 时, 由于导数不存在, 因此尝试通过次梯度求解: 令 $f(p_i) = \|p_i\|^2$, 当 $p_i = 0$ 时,

$$\begin{aligned} \frac{\partial f(p_i)}{\partial p_i} = & \{v \in R^d | f(p_i') \leq f(p_i) + v^T (p_i' - p_i), \forall p_i' \in R^d\} \\ = & \{v \in R^d | \|p_i'\|_2 \leq v^T p_i', \forall p_i' \in R^d\} \end{aligned} \quad (8)$$

因此, p_i 的次梯度向量 v 在 $p_i = 0$ 时, 需要满足 $\|v\| \leq 1$. 并且KKT条件要求 $0 \in -y_i + \lambda v + \tau - \mu_i$, 所以我们可以得到:

$$\begin{aligned} -y_i + \lambda v + \tau - \mu_i &= 0 \\ \lambda v &= y_i - \tau + \mu_i \\ v &= \frac{1}{\lambda}(y_i - \tau + \mu_i) \\ v &= \frac{1}{\lambda}s_i \end{aligned} \quad (9)$$

由于 $\|v\|_2 \leq 1$, 所以得到:

$$\begin{aligned} \|\frac{1}{\lambda}s_i\|_2 &\leq 1 \\ \|s_i\|_2 &\leq \lambda \end{aligned} \quad (10)$$

所以, 当 $\|s_i\|_2 \leq \lambda$ 时, $p_i = 0$ 。

通过上面的分析可以得出 p_i 的解的形式为:

$$\begin{aligned} p_i &= (1 - \frac{\lambda}{\|s_i\|_2})_+ s_i \\ &= (1 - \frac{\lambda}{\|(y_i - \tau + \mu_i)_+\|_2})_+ (y_i - \tau + \mu_i)_+ \end{aligned} \quad (11)$$

进一步由Eq. 4可知, 当 $p_i > 0$ 时 $\mu_i = 0$, 因此, 可化简为:

$$p_i = (1 - \frac{\lambda}{\|(y_i - \tau)_+\|_2})_+ (y_i - \tau)_+ \quad (12)$$